پاسخ مسئله‌ی ۱.

الف

گرادیان‌ها از همبستگی W با ماسک‌ها:

$$g_۱ = \sum H_۱ \odot W = (-۱)(۲) + (۰)(۴) + (۱)(۸) + (-۲)(۲) + (۰)(۸) + (۲)(۸) + (-۱)(۲) + (۰)(۸) + (۱)(۸)$$
$$= -۲ + ۸ - ۴ + ۱۶ - ۲ + ۸ = ۲۴$$
$$g_۲ = \sum H_۲ \odot W = (-۱)(۲) + (-۲)(۴) + (-۱)(۸) + ۰ + ۰ + ۰ + (۱)(۲) + (۲)(۸) + (۱)(۸)$$
$$= -۲ - ۸ - ۸ + ۲ + ۱۶ + ۸ = ۸$$
$$g = \sqrt{g_۱^۲ + g_۲^۲} = \sqrt{۲۴^۲ + ۸^۲} = \sqrt{۶۴۰} = ۸\sqrt{۱۰} \approx ۲۵/۳$$

ب

پاسخ Laplacian از همبستگی L با W:

$$\nabla^۲ f = ۸(۸) - (۲ + ۴ + ۸ + ۲ + ۸ + ۲ + ۸ + ۸)$$
$$= ۶۴ - ۴۲ = ۲۲$$

پاسخ مسئله‌ی ۲.

الف

بنا بر تعریف کانولوشن پیوسته:

$$(G_\sigma * f)(x,y) = \iint_{\mathbb{R}^2} G_\sigma(x-u,\, y-v)\, f(u,v)\, \mathrm{d}u\, \mathrm{d}v$$

با مشتق‌گیری نسبت به x و انتقال عملگر مشتق به زیر انتگرال (مجاز است، چون f مستقل از x و G_σ نسبت به x به‌قدر کافی هموار و انتگرال‌پذیر است):

$$\begin{aligned}
\frac{\partial}{\partial x}(G_\sigma * f)(x,y) &= \frac{\partial}{\partial x}\iint G_\sigma(x-u,\, y-v)\, f(u,v)\, \mathrm{d}u\, \mathrm{d}v \\
&= \iint \frac{\partial}{\partial x} G_\sigma(x-u,\, y-v)\, f(u,v)\, \mathrm{d}u\, \mathrm{d}v \\
&= \iint \left(\frac{\partial G_\sigma}{\partial x}\right)(x-u,\, y-v)\, f(u,v)\, \mathrm{d}u\, \mathrm{d}v \\
&= \left(\frac{\partial G_\sigma}{\partial x} * f\right)(x,y)
\end{aligned}$$

انتقال مشتق به زیر انتگرال با Leibniz integral rule و قاعدهٔ زنجیری $\partial_x G_\sigma(x-u,\cdot) = (\partial_x G_\sigma)(x-u,\cdot)$ توجیه می‌شود؛ هموار و سریعاً میرا بودن گاوسی شرط جابه‌جایی را تأمین می‌کند.

ب

مشتق‌گیری عملگری است که نوفهٔ فرکانس‌بالا را تقویت می‌کند؛ در حوزهٔ فرکانس ضریب آن $|\omega| \propto$ است:

$$\mathcal{F}\{\partial_x f\}(\omega) = j\omega_x\, \hat{f}(\omega)$$

از این رو مشتق‌گیری مستقیم روی تصویر خام، نوفهٔ موجود را به‌شدت بزرگ‌نمایی می‌کند و لبه‌های واقعی در میان پاسخ‌های کاذب گم می‌شوند. گاوسی یک Low-pass filter است و حاصل‌ضرب طیف آن با $|\omega|$ یک پاسخ Band-pass می‌سازد که نوفهٔ فرکانس‌بالا را پیش از مشتق‌گیری سرکوب می‌کند. افزون بر این، مشتق روی شبکهٔ گسسته ill-posed است و تنها پس از هموارسازی پایدار و معنادار می‌شود؛ پارامتر σ نیز مقیاس لبه‌های آشکارشده را کنترل می‌کند.

ج

عملگر Laplacian (و LoG) در شرایط زیر بر گرادیان مرتبهٔ اول برتری دارد:

- ایزوتروپ بودن: ∇^2 نسبت به دوران ناورداست و به جهت لبه وابسته نیست، در حالی‌که آشکارساز گرادیانی نیازمند ترکیب مؤلفه‌های جهتی است.
- مکان‌یابی دقیق لبه از طریق Zero-crossing؛ عبور از صفر در $\nabla^2(G_\sigma * f) = 0$ مرز را با ضخامت یک پیکسل و بسته (پیوسته) مشخص می‌کند، حال آن‌که بیشینهٔ گرادیان لبه‌ای ضخیم و نیازمند آستانه‌گذاری می‌دهد.

- تشخیص هم‌زمان لبه‌ها در همهٔ جهت‌ها با یک کانولوشن واحد و به‌صرفه از نظر محاسباتی.
- مناسب برای آشکارسازی نقاط، خطوط نازک و بافت‌های ریز که تغییر مرتبهٔ دوم در آن‌ها بارزتر است.

کاربرد بهینه آنجاست که تصویر پس از هموارسازیِ گاوسی نوفهٔ کنترل‌شده دارد و لبه‌ها به‌صورت گذارهای ملایم شدت ظاهر می‌شوند؛ در این حالت LoG با انتخاب مناسب σ مرزهای بسته و دقیق استخراج می‌کند.

پاسخ مسئله‌ی ۳.

الف

با بسط مجذور:

$$\begin{aligned}\sigma_\eta^2(p,q) &= \sum_m \sum_n \big[v(m,n) - u(m-p,n-q)\big]^2 \\ &= \sum_m \sum_n v^2(m,n) - 2\sum_m \sum_n v(m,n)\,u(m-p,n-q) \\ &\quad + \sum_m \sum_n u^2(m-p,n-q) \\ &= \underbrace{\sum_m \sum_n v^2(m,n)}_{\text{ثابت}} - 2\,c_{vu}(p,q) + \underbrace{\sum_m \sum_n u^2(m-p,n-q)}_{\text{ثابت}\approx}\end{aligned}$$

جملهٔ نخست به (p,q) وابسته نیست و جملهٔ سوم نیز انرژی u است که با فرض هم‌پوشانی کامل مستقل از جابه‌جایی (تقریباً ثابت) است؛ پس تنها جملهٔ وابسته به (p,q) همان $-2c_{vu}(p,q)$ است:

$$\arg\min_{(p,q)} \sigma_\eta^2(p,q) = \arg\max_{(p,q)} c_{vu}(p,q)$$

از این رو کمینه‌کردن انرژی عدم‌تطابق هم‌ارز با بیشینه‌کردن cross-correlation است.

ب

با نامساوی Cauchy-Schwarz:

$$|c_{vu}(p,q)| = \left|\sum_m \sum_n v(m,n)\,u(m-p,n-q)\right| \le \sqrt{\sum_m \sum_n v^2}\,\sqrt{\sum_m \sum_n u^2}$$

تساوی (بیشینهٔ مطلق) دقیقاً زمانی برقرار است که دو سیگنال به‌طور خطی وابسته باشند:

$$v(m,n) = \alpha\,u(m-p,n-q), \qquad \alpha > 0$$

یعنی هنگامی که الگوی جابه‌جاشدهٔ u مضرب اسکالر مثبت v باشد (تطابق کامل در آن جابه‌جایی).

پاسخ مسئله‌ی ۴.

الف

هدف، بیشینه‌سازی نسبت پراکندگی بین‌کلاسی به درون‌کلاسی پس از تصویر روی w است:

$$J(w) = \frac{w^T B\, w}{w^T S\, w}$$

که در آن B ماتریس پراکندگی بین‌کلاسی (Between-class scatter) و S ماتریس پراکندگی درون‌کلاسی (Within-class scatter) است:

$$B = (\mu_۱ - \mu_۲)(\mu_۱ - \mu_۲)^T$$
$$S = \sum_c \sum_{x \in c} (x - \mu_c)(x - \mu_c)^T$$

بیشینه‌ساز با حل $S^{-۱} B\, w = \lambda w$ به‌دست می‌آید.

ب

تخصیص. فاصلهٔ مربعی هر نقطه تا دو مرکز $c_۱ = (۱, ۱)$ و $c_۲ = (۵, ۴)$:

$$x_۱ = (۱, ۱): \quad d^۲(x_۱, c_۱) = ۰, \quad d^۲(x_۱, c_۲) = ۱۶ + ۹ = ۲۵ \;\Rightarrow\; C_۱$$
$$x_۲ = (۲, ۱): \quad d^۲(x_۲, c_۱) = ۱ + ۰ = ۱, \quad d^۲(x_۲, c_۲) = ۹ + ۹ = ۱۸ \;\Rightarrow\; C_۱$$
$$x_۳ = (۴, ۳): \quad d^۲(x_۳, c_۱) = ۹ + ۴ = ۱۳, \quad d^۲(x_۳, c_۲) = ۱ + ۱ = ۲ \;\Rightarrow\; C_۲$$
$$x_۴ = (۵, ۴): \quad d^۲(x_۴, c_۱) = ۱۶ + ۹ = ۲۵, \quad d^۲(x_۴, c_۲) = ۰ \;\Rightarrow\; C_۲$$

بنابراین $C_۱ = \{x_۱, x_۲\}$ و $C_۲ = \{x_۳, x_۴\}$.

به‌روزرسانی مراکز.

$$c_۱ = \tfrac{۱}{۲}\big((۱, ۱) + (۲, ۱)\big) = (۱٫۵,\ ۱)$$
$$c_۲ = \tfrac{۱}{۲}\big((۴, ۳) + (۵, ۴)\big) = (۴٫۵,\ ۳٫۵)$$